

Inferência para uma Proporção

Inferência para uma Proporção

- Na prática, os modelos de amostragem Poisson e binomial tem valores para os parâmetros desconhecidos. O método mais utilizado para se estimar parâmetros é o método da máxima verossimilhança.

O Princípio da Máxima Verossimilhança

Afirma que devemos escolher aquele valor do parâmetro desconhecido que **maximiza** a probabilidade de obter a amostra observada, ou seja, o valor que torna aquela amostra "**mais provável**" (**verossímil**).

- Este princípio foi enunciado por Fisher pela primeira vez em 1912.
- Em 1922, ele introduziu a expressão "likelihood" quando deu-lhe forma mais completa.
- Usa o princípio da máxima verossimilhança para obter os estimadores de máxima verossimilhança que, em geral, têm propriedades muito boas.

Função de Verossimilhança

Seja X uma v.a. com função de probabilidade $p(x;\theta)$ ou função densidade de probabilidade $f(x;\theta)$.

Seja uma amostra aleatória de tamanho n de X , (X_1, X_2, \dots, X_n) , e sejam (x_1, x_2, \dots, x_n) os valores efetivos observados.

A FUNÇÃO DE VEROSSIMILHANÇA é definida por:

$$L(\theta) = L(\theta; x_1, x_2, \dots, x_n) = \begin{cases} \prod_{i=1}^n p(x_i; \theta) & \text{se } X \text{ v.a. discreta} \\ \prod_{i=1}^n f(x_i; \theta) & \text{se } X \text{ v.a. contínua} \end{cases}$$

o qual é considerada uma função de θ .

Estimação de Máxima Verossimilhança

Seja

$$L(\theta) = L(\theta; x_1, x_2, \dots, x_n)$$

a função de verossimilhança para (X_1, X_2, \dots, X_n) .

Se

$$\hat{\theta} = g(X_1, X_2, \dots, X_n)$$

é o valor de θ que maximiza $L(\theta)$, então $\hat{\theta}$ é o estimador de máxima verossimilhança (MV) de θ e

$$\hat{\theta} = g(x_1, x_2, \dots, x_n) \text{ é a estimativa MV de } \theta.$$

Estimação de Máxima Verossimilhança

Sob condições de regularidade da função de verossimilhança, **o estimador MV** é a solução da equação:

$$\frac{\partial L(\theta)}{\partial \theta} = 0$$

Temos ainda que $L(\theta)$ e $l(\theta) = \ln L(\theta)$ têm máximo no mesmo valor de θ , e às vezes é mais fácil encontrar o máximo de $l(\theta) = \ln L(\theta)$.

Estimação por Máxima Verossimilhança

- Para um particular modelo de amostragem, podemos substituir os dados da amostra na função de probabilidade e então ver a probabilidade como uma função de valores do parâmetro desconhecido.

- **Exemplo:**

Em $n = 10$ ensaios, suponha uma binomial com $Y = 0$. Da fórmula da binomial com parâmetro π , a probabilidade do resultado é igual a:

$$P(0) = (1 - \pi)^{10}$$

Esta probabilidade é definida para valores entre 0 e 1.

Estimação por Máxima Verossimilhança

- A probabilidade dos dados observados, expressa como uma função do parâmetro, é chamada de **função de verossimilhança**.

A função de verossimilhança para $Y = 0$ sucessos em 10 ensaios é dada por:


$$l(\pi) = (1 - \pi)^{10}, \quad 0 \leq \pi \leq 1$$

- A estimativa de máxima verossimilhança do parâmetro é definido como sendo o valor na qual a probabilidade dos dados observados assume o seu maior valor. Ou seja, é o valor na qual a função de verossimilhança assume o seu máximo.

Estimação por Máxima Verossimilhança

- O gráfico de $l(\pi)$ para $n = 10$ e $Y = 0$, assume o máximo no ponto $\pi = 0$.
- Geralmente, uma binomial com y sucessos em n ensaios tem estimativa de máxima verossimilhança de π igual a $p = y/N$. Isto é, a proporção de sucessos da amostra para N ensaios.
- Denotando por 1 o sucesso e 0 a falha. Então a proporção da amostra é igual a média da amostra dos resultados do ensaio.

- O gráfico de $l(\pi)$ para $n = 10$ e $Y = 0$, assume o máximo no ponto $\pi = 0$.



- Geralmente, uma Binomial com y sucessos em n ensaios tem estimador de máxima verossimilhança de π igual a

$$\hat{p} = \frac{Y}{n},$$

isto é, a **proporção de sucessos da amostra** para n ensaios.

- Denotando por 1 o sucesso e 0 a falha. Então a proporção da amostra é igual a média da amostra dos resultados do ensaio.

Estimação por Máxima Verossimilhança

- A distribuição de Poisson também tem estimativa de máxima verossimilhança igual a média amostral.
- Os estimadores baseados no método da máxima verossimilhança são muito populares porque eles tem propriedades interessantes para grandes amostras:
 - Os estimadores de máxima verossimilhança são aqueles que apresentam os menores erros padrões.
 - Os estimadores de máxima verossimilhança são aproximadamente normais.

Distribuição Amostral de \hat{p}

Vamos considerar uma população em que a proporção de elementos portadores de uma certa característica é π .

Assim, a população pode ser considerada como a variável X , tal que:

$$X = \begin{cases} 1 & \text{se o elemento é portador da característica} \\ 0 & \text{se o elemento não é portador da característica} \end{cases}$$

Logo X tem distribuição de Bernoulli e

$$\mu = E(X) = \pi \text{ e } V(X) = \pi(1 - \pi)$$

- Observe que:

$$p = \frac{\text{núm. de elementos da população com a característica}}{n} = \frac{\sum_{i=1}^N X_i}{N}$$

Logo a PROPORÇÃO é uma particular média.

- Retirada uma amostra aleatória simples de tamanho n dessa população e, se indicarmos por:

$$Y_n = \sum_{i=1}^n X_i \rightarrow \text{total de indivíduos com a característica na amostra}$$

Temos que:

$$Y: \text{Binomial}(n, \pi) \text{ e } E(Y_n) = n\pi \text{ e } V(Y_n) = n\pi(1 - \pi)$$

- Definindo como \hat{P} a **proporção de elementos da amostra** com a característica em estudo, isto é,

$$\hat{P} = \frac{Y_n}{n} = \frac{\sum_{i=1}^n X_i}{n} = \bar{X}$$

Logo \hat{P} é também um caso particular de \bar{X} e portanto, são válidos os resultados encontrados para \bar{X}
Assim,

$$\mu_{\hat{P}} = E(\hat{P}) = \pi \text{ e } \sigma_{\hat{P}}^2 = V(\hat{P}) = \frac{\pi(1 - \pi)}{n}$$

◆ Pequenas Amostras:

$$P\left(\hat{P} = \frac{y}{n}\right) = P\left(\frac{Y_n}{n} = \frac{y}{n}\right) = P(Y_n = y)$$

sendo: $Y_n: \text{Binomial}(n, \pi)$

■ Grandes Amostras:

- Se n é grande, pelo TEOREMA CENTRAL DO LIMITE (uma vez que X não é normal) temos que:

$$\hat{P} \sim N\left(\pi, \frac{\pi(1 - \pi)}{n}\right)$$

Estimação da Proporção Populacional

Deseja-se estimar a proporção de elementos da população (π) que apresentam certa característica.

■ ESTIMADOR de π : \hat{P}

- Distribuição amostral de \hat{P} :
Se n é "grande" temos que:

$$\hat{P} \sim N\left(\pi, \frac{\pi(1 - \pi)}{n}\right)$$

E conseqüentemente,

$$Z = \frac{\hat{P} - \pi}{\sqrt{\frac{\pi(1 - \pi)}{n}}} \sim N(0, 1)$$

Intervalo de Confiança (γ) para π

Fixada uma confiança γ tem-se na $N(0, 1)$:

$$P\left(-z < \frac{\hat{P} - \pi}{\sqrt{\frac{\pi(1-\pi)}{n}}} < z\right) = \gamma \quad \Rightarrow \quad P\left(\hat{P} - z\sqrt{\frac{\pi(1-\pi)}{n}} < \pi < \hat{P} + z\sqrt{\frac{\pi(1-\pi)}{n}}\right) = \gamma$$

Assim:

$$\pi \in \left(\hat{P} - z\sqrt{\frac{\pi(1-\pi)}{n}}; \hat{P} + z\sqrt{\frac{\pi(1-\pi)}{n}}\right)$$

Observe-se, porém, que não se conhece o valor de π e, portanto $\pi(1-\pi)$ é também desconhecido.

◆ **Solução:**

$$\pi \in \left(\hat{P} \mp z\sqrt{\frac{\hat{p}(1-\hat{P})}{n}}\right)$$

Intervalo de Confiança (γ) para p

◆ **Solução 1:**

$$p \in \left(\hat{P} - z\sqrt{\frac{\hat{P}(1-\hat{P})}{n}}; \hat{P} + z\sqrt{\frac{\hat{P}(1-\hat{P})}{n}}\right)$$

◆ **Solução 2:**

$$p \in \left(\hat{P} - z\sqrt{\frac{1}{4n}}; \hat{P} + z\sqrt{\frac{1}{4n}}\right)$$

Usando o fato de que
 $P(1-p) = 1/4$