



Modelos Log-lineares

Maria Teresa Leão Costa

Modelos Log-lineares

- Metodologia apropriada quando não existe distinção clara entre variável resposta e variáveis explicativas.
- Todas as variáveis são tratadas como resposta e o foco está na independência estatística.

Os MODELOS LOG-LINEARES descrevem padrões de associação e interação entre variáveis categorizadas.

Modelos Log-lineares

- Com a abordagem log-linear, modela-se as frequências de uma tabela de contingência em termos da associação entre variáveis.
- Os modelos log-lineares especificam como a frequência de uma célula depende dos níveis das variáveis categóricas para aquela célula.

Modelos Log-lineares para Tabelas Bidimensionais

Tabelas 2x2

- *Suponha uma amostra de tamanho n classificada segundo duas variáveis binárias X e Y .*

Grupo	Y		Total
	Sucesso	Insucesso	
1	n_{11}	n_{12}	n_{1+}
2	n_{21}	n_{22}	n_{2+}
Total	n_{+1}	n_{+2}	n

Modelos Log-lineares para Tabelas Bidimensionais

- As probabilidades π_{ij} para distribuição multinomial formam a distribuição conjunta das duas variáveis categorizadas.

X	Y		Total
	1	2	
1	π_{11}	π_{12}	π_{1+}
2	π_{21}	π_{22}	π_{2+}
Total	π_{+1}	π_{+2}	1

- Os modelos log-lineares usam as frequências esperadas $\mu_{ij} = n \cdot \pi_{ij}$ em vez das probabilidades π_{ij} .

→ n_{ij} - frequências das células tem distribuição de Poisson com parâmetro μ_{ij}

Ou em termos da “odds ratio”:

$$\theta = \frac{\pi_{11} \cdot \pi_{22}}{\pi_{12} \cdot \pi_{21}} = 1$$

A odds ratio pode ser expressa também em termos das frequências esperadas, onde $\mu_{ij} = n \cdot \pi_{ij}$

$$\theta = \frac{\mu_{11} \cdot \mu_{22}}{\mu_{12} \cdot \mu_{21}} = 1$$

Tomando o logaritmo, em ambos os lados, temos que:

$$\log(\theta) = \log(\mu_{11}) - \log(\mu_{12}) - \log(\mu_{21}) + \log(\mu_{22}) = 0$$

ou seja, a independência estatística pode ser expressa como uma combinação linear dos logaritmos das frequências esperadas.

Modelo de Independência

- Se X e Y são independentes então:

$$\pi_{ij} = \pi_{i+} \cdot \pi_{+j}$$

- A expressão relacionada as frequências esperadas é dada por:

$$\mu_{ij} = n \pi_{i+} \pi_{+j}$$

Modelo de Independência

- Na escala logarítmica, a independência tem a forma aditiva

$$\log \mu_{ij} = \log n + \log \pi_{i+} + \log \pi_{+j}$$

- Denotando a variável linha por X e a variável coluna por Y , a expressão acima é equivalente a:

$$\log \mu_{ij} = \lambda + \lambda_i^X + \lambda_j^Y$$

Efeito linha- efeito da classificação na linha i

Efeito coluna- efeito da classificação na coluna j

- O modelo especifica como as contagens esperadas das células variam de acordo com as categorias de X e Y .

- O modelo considera as observações como contagens de células em vez de classificações de indivíduos.

- H_0) X e Y independentes

$$H_0) X \text{ e } Y \text{ independentes} \Leftrightarrow H_0) \log(\mu_{ij}) = \lambda + \lambda_i^X + \lambda_j^Y$$

- Os valores ajustados que satisfazem ao modelo log-linear de independência são:

$$\hat{\mu}_{ij} = \frac{n_{i+} \cdot n_{+j}}{n}$$

Modelos loglineares para tabelas de contingência são **modelos lineares generalizados** que:

- tratam as contagens de células como *observações independentes das distribuições de Poisson*
- usam a **função de link - log**.

Interpretação dos Parâmetros

- No modelo de independência a diferença entre dois parâmetros para uma dada variável indica o log da odds de uma resposta com relação a outra, nesta variável.

- Exemplo:**

Seja uma tabela Ix2 (X com I níveis e Y com dois níveis)

Considere $\pi = P(Y=1) = P(\text{sucesso})$.

Para a linha i temos que:

$$\log\left(\frac{\pi}{1-\pi}\right) = \log\left(\frac{\mu_{i1}}{\mu_{i2}}\right) = \log(\mu_{i1}) - \log(\mu_{i2}) =$$

$$= (\lambda + \lambda_i^X + \lambda_1^Y) - (\lambda + \lambda_i^X + \lambda_2^Y) = \lambda_1^Y - \lambda_2^Y$$

⇒ Não depende de i , isto é, logito para Y não depende do nível de X

⇒ independe da parametrização usada

Modelo Log-linear Saturado

O Modelo Log-linear saturado para tabela 2x2 é:

$$\log(\mu_{ij}) = \mu + \lambda_i^X + \lambda_j^Y + \lambda_{ij}^{XY} \quad i=1,2 \quad e \quad j=1,2$$

onde $\mu_{ij} = n\pi_{ij}$ é a frequência esperada da célula (i,j) .

- Os parâmetros λ_{ij}^{XY} são termos de associação – representam interações entre X e Y, em que o efeito de qualquer variável na frequência esperada das células depende da categoria da outra variável.
- O modelo descreve perfeitamente qualquer conjunto de frequências esperadas.
- É o modelo mais geral para tabelas de contingência bidimensional.

Este modelo é similar a uma Análise de Variância com 2 fatores para uma variável resposta Y:

$$E(y_{ij}) = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij}$$

onde:

μ – efeito médio geral

α_i
 β_j } efeitos principais dos fatores 1e2

$(\alpha\beta)_{ij}$ – efeito da interação

$$\log(\mu_{ij}) = \mu + \lambda_i^X + \lambda_j^Y + \lambda_{ij}^{XY}$$

onde:

μ – termo baseado no tamanho da amostra

λ_i^X – efeito da classificação na linha i para variável X

λ_j^Y – efeito da classificação na linha j para variável Y

λ_{ij}^{XY} – efeito da interação entre X e Y

Observe que no modelo linear saturado para tabelas 2x2 :

$$\log(\mu_{ij}) = \mu + \lambda_i^X + \lambda_j^Y + \lambda_{ij}^{XY} \quad i=1,2 \quad e \quad j=1,2$$

no. de parâmetros:

$$1 + 2 + 2 + 4 = 9$$

$$(\lambda_1^X, \lambda_2^X) \quad (\lambda_1^Y, \lambda_2^Y) \quad (\lambda_{11}^{XY}, \lambda_{12}^{XY}, \lambda_{21}^{XY}, \lambda_{22}^{XY})$$

⇒ Modelo Superparametrizado

■ Restrições:

$$\sum_{i=1}^2 \lambda_i^X = 0, \quad \sum_{j=1}^2 \lambda_j^Y = 0, \quad \sum_{i=1}^2 \lambda_{ij}^{XY} = \sum_{j=1}^2 \lambda_{ij}^{XY} = 0$$

produz 3 parâmetros não redundantes:

$$\lambda_1^X, \quad \lambda_1^Y, \quad \lambda_{11}^{XY}$$

O quarto parâmetro, μ , é fixado pelo tamanho da amostra n .

Relação direta entre log (odds ratio) e λ_{ij}^{XY}

Temos que "odds ratio":

$$\theta = \frac{\pi_{11} \cdot \pi_{22}}{\pi_{12} \cdot \pi_{21}} = 1$$

A odds ratio pode ser expressa também em termos das frequências esperadas, onde $\mu_{ij} = n \pi_{i+} \pi_{+j}$

$$\theta = \frac{\mu_{11} \cdot \mu_{22}}{\mu_{12} \cdot \mu_{21}} = 1$$

Tomando o logaritmo, em ambos os lados, temos que:

$$\log(\theta) = \log(\mu_{11}) - \log(\mu_{12}) - \log(\mu_{21}) + \log(\mu_{22}) = 0$$

ou seja, a independência estatística pode ser expressa como uma combinação linear dos logaritmos das frequências esperadas.

Interpretação dos Parâmetros

- Existe uma relação direta entre a razão de chances e os parâmetros de associação dos modelos log-lineares. A relação é mais simples para uma tabela 2x2.
- Para o modelo saturado

$$\log \theta = \log \left(\frac{\mu_{11} \mu_{22}}{\mu_{12} \mu_{21}} \right) = \log \mu_{11} + \log \mu_{22} - \log \mu_{12} - \log \mu_{21}$$

- Assim:

$$\begin{aligned} \log(\theta) &= (\mu + \lambda_1^X + \lambda_1^Y + \lambda_{11}^{XY}) + (\mu + \lambda_2^X + \lambda_2^Y + \lambda_{22}^{XY}) \\ &\quad - (\mu + \lambda_1^X + \lambda_2^Y + \lambda_{12}^{XY}) - (\mu + \lambda_2^X + \lambda_1^Y + \lambda_{21}^{XY}) = \\ &= \lambda_{11}^{XY} + \lambda_{22}^{XY} - \lambda_{12}^{XY} - \lambda_{21}^{XY} \end{aligned}$$

Interpretação dos Parâmetros

- Das restrições :

$$\sum_i \lambda_{ij}^{XY} = \sum_j \lambda_{ij}^{XY} = 0 \Rightarrow \begin{cases} \{\lambda_{11}^{XY} + \lambda_{21}^{XY} = 0 \Rightarrow \lambda_{11}^{XY} = -\lambda_{21}^{XY} \\ \{\lambda_{12}^{XY} + \lambda_{22}^{XY} = 0 \Rightarrow \lambda_{12}^{XY} = -\lambda_{22}^{XY} \\ \{\lambda_{11}^{XY} + \lambda_{12}^{XY} = 0 \Rightarrow \lambda_{11}^{XY} = -\lambda_{12}^{XY} \\ \{\lambda_{21}^{XY} + \lambda_{22}^{XY} = 0 \Rightarrow \lambda_{21}^{XY} = -\lambda_{22}^{XY} \end{cases}$$

Assim:

$$\begin{aligned} \log(\theta) &= \lambda_{11}^{XY} + \lambda_{22}^{XY} - \lambda_{12}^{XY} - \lambda_{21}^{XY} = \\ &= \lambda_{11}^{XY} + (-\lambda_{21}^{XY}) + (+\lambda_{11}^{XY}) - \lambda_{21}^{XY} = \\ &= \lambda_{11}^{XY} + (\lambda_{11}^{XY}) + (+\lambda_{11}^{XY}) + \lambda_{11}^{XY} = 4 \lambda_{11}^{XY} \end{aligned}$$

Interpretação dos Parâmetros

- Temos então que:

$$\log \theta = 4\lambda_{11}^{XY}$$

A razão de chances para uma tabela 2x2 é igual ao antilog de quatro vezes o parâmetros de associação no modelo log-linear saturado.

Modelo Log-linear de Independência

Se X e Y são independentes $\theta=1$ e $\log(\theta)=\log(1)=0$, mas :

$$\log(\theta) = 4\lambda_{ij}^{XY} \quad i=1,2 \quad e \quad j=1,2$$

Assim testar independência equivale a testar:

$$H_0) \lambda_{ij}^{XY} = 0 \quad i=1,2 \quad e \quad j=1,2$$

Neste caso temos o Modelo Log-linear de Independência

$$\log(\mu_{ij}) = \mu + \lambda_i^X + \lambda_j^Y \quad i=1,2 \quad e \quad j=1,2$$

Modelo Log-linear de Independência

Se X e Y são independentes $\theta=1$ e $\log(\theta)=\log(1)=0$, mas :

$$\log(\theta) = 4\lambda_{ij}^{XY} \quad i=1,2 \quad e \quad j=1,2$$

Assim testar independência equivale a testar:

$$H_0) \lambda_{ij}^{XY} = 0 \quad i=1,2 \quad e \quad j=1,2$$

Neste caso temos o Modelo Log-linear de Independência

$$\log(\mu_{ij}) = \mu + \lambda_i^X + \lambda_j^Y \quad i=1,2 \quad e \quad j=1,2$$

Tabelas $I \times J$

- Modelo Log-linear saturado:

$$\log(\mu_{ij}) = \mu + \lambda_i^X + \lambda_j^Y + \lambda_{ij}^{XY} \quad i=1, \dots, I \quad e \quad j=1, 2, \dots, J$$


com as restrições:

$$\sum_{i=1}^I \lambda_i^X = 0, \quad \sum_{j=1}^J \lambda_j^Y = 0, \quad \sum_{i=1}^I \lambda_{ij}^{XY} = \sum_{j=1}^J \lambda_{ij}^{XY} = 0$$

o que implica em $IJ-1$ parâmetros não redundantes.

- Modelo Log-linear de Independência:

$$\log(\mu_{ij}) = \mu + \lambda_i^X + \lambda_j^Y \quad i=1, \dots, I \quad e \quad j=1, 2, \dots, J$$

- 
- No **modelo saturado**, como já foi visto, existe uma relação direta entre a log da *odds ratio* e os parâmetros de associação, λ_{ij}^{XY} , a saber:

$$\log(\theta) = \lambda_{11}^{XY} + \lambda_{22}^{XY} - \lambda_{12}^{XY} - \lambda_{21}^{XY}$$