

## Introdução à Regressão Logística

### Parte 4 – Modelo de Regressão Logística Múltiplo

#### Unidade III

## Modelo de Regressão Logística Múltiplo

- Seja o conjunto de  $p$  variáveis explicativas ou regressoras para variável resposta binária  $Y$  designado por
$$x = (x_1, x_2, \dots, x_p)$$
- O objetivo é modelar a probabilidade de sucesso como uma função de valores fixados das variáveis explicativas, isto é,
$$\pi(x) = P(Y = 1 | x_1, x_2, \dots, x_p)$$
- Sejam  $x_{i1}, x_{i2}, \dots, x_{ip}$  valores fixados das variáveis explicativas,  $i=1, 2, \dots, c$  onde  $x_{ij}$  representa um valor referente à variável  $X_j$ .

## Modelo de Regressão Logística Múltiplo

O modelo será

$$\pi_i = \frac{\exp(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip})}{1 + \exp(\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip})}, \quad i = 1, \dots, c$$

### ■ Transformação logito:

$$\log \text{ito}(\pi_i) = \ln \left( \frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}$$

- O parâmetro  $\beta_j$  refere-se ao efeito do acréscimo de uma unidade em  $X_j$  sobre o  $\ln$  da *odds* de  $Y=1$ , mantendo as outras variáveis explicativas constantes.
- Assim,  $\exp(\beta_j)$  é o efeito multiplicativo na chance (*odds*) de  $Y=1$  para o acréscimo de 1 unidade em  $X_j$ , mantendo as demais variáveis explicativas constantes.

## PROBLEMA

### Caranguejo Ferradura

*Amostra de 173 fêmeas. As seguintes características foram investigadas para cada uma delas:*

- Z - cor da carapaça  
( 1- clara média      2 - média  
3 - escura média    4 - escura )
- X - largura da carapaça da fêmea em cm;
- Y - se a fêmea tem pelo menos um satélite ( 1 – sim e 0- não)

Cor é um indicador para idade dos caranguejos: caranguejos mais velhos tendem a ser mais escuros. A categoria de referência será a *cor escura*.

O modelo a ser ajustado será:

$$\log \text{ito}(\pi) = \beta_0 + \beta_{11} D_1 + \beta_{12} D_2 + \beta_{13} D_3 + \beta_2 x$$

## Modelo com Variável Independente Qualitativa

- Uma variável independente qualitativa tendo  $l$  níveis requer  $l-1$  variáveis *dummy*.
- Suponha que a  $j$ -ésima variável independente,  $X_j$ , tenha  $l_j$  níveis. Designando as  $l_j-1$  variáveis *dummy* como  $D_{iju}$  e os seus respectivos coeficientes por  $\beta_{ju}$ ,  $u=1,2,\dots,l_j-1$

$$\log \text{ito}(\pi_i) = \ln\left(\frac{\pi_i}{1-\pi_i}\right) = \beta_0 + \beta_1 x_{i1} + \dots + \sum_{u=1}^{l_j-1} \beta_{ju} D_{iju} + \dots + \beta_p x_{ip}$$

- Em termos matriciais temos:

$$\beta_{p \times 1} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{p-1} \end{bmatrix} \quad X_{p \times 1} = \begin{bmatrix} 1 \\ X_1 \\ X_2 \\ \vdots \\ X_{p-1} \end{bmatrix}$$

- Assim:

$$X'\beta = \beta_0 + \beta_1 X_1 + \dots + \beta_{p-1} X_{p-1}$$

- E portanto:

$$E\{Y\} = \frac{\exp(X'\beta)}{1 + \exp(X'\beta)}$$

## Estimação dos Parâmetros do Modelo

→ *Método de máxima verossimilhança*

$$\ln L(\beta) = \sum_{i=1}^n Y_i (X'_i \beta) - \sum_{i=1}^n \ln[1 + \exp(X'_i \beta)]$$

- Procedimentos numéricos são usados para encontrar os valores de  $\beta_0, \beta_1, \dots, \beta_{p-1}$  que maximizam  $\ln L(\beta)$ . Essas estimativas de máxima verossimilhança serão designadas por  $b_0, b_1, \dots, b_{p-1}$ .

Seja  $b$  o vetor das estimativas de máxima verossimilhança:

$$b_{p \times 1} = \begin{bmatrix} b_0 \\ b_1 \\ \vdots \\ b_{p-1} \end{bmatrix}$$

## Inferência sobre os parâmetros do Modelo

- Os procedimentos de inferência dependem de amostras de tamanhos de grandes.

Sob condições geralmente aplicáveis, estimadores de máxima verossimilhança para regressão logística são:

- aproximadamente normalmente distribuídos;
- apresentam pouco ou nenhum viés;
- e tem as correspondentes variâncias e covariâncias aproximadas que são funções das derivadas parciais de segunda ordem do logaritmo da função de verossimilhança.

## Inferência sobre os parâmetros do Modelo

Seja  $\mathbf{G}$  a matriz de derivadas parciais de segunda ordem do  $\log$  da função de verossimilhança, as derivadas sendo tomadas em relação aos parâmetros do modelo.

$$\mathbf{G}_{p \times p} = [g_{ij}] \quad i = 0, 1, \dots, p-1; j = 0, 1, \dots, p-1$$

$$g_{00} = \frac{\partial^2 \log_e L(\beta)}{\partial \beta_0^2}$$

$$g_{01} = \frac{\partial^2 \log_e L(\beta)}{\partial \beta_0 \partial \beta_1}$$

etc.

**matriz de Hessiana**

$$s^2\{b\} = (-g_{ij}|_{\beta=b})^{-1}$$

Inferências sobre os coeficientes de regressão para o modelo de regressão logística simples são baseados nos seguintes resultados aproximados quando o tamanho da amostra é grande:

$$Z = \frac{\beta_k - b_k}{s\{b_k\}} \sim N(0,1), \quad k = 0, 1, \dots, p-1.$$

## Teste referente a um único parâmetro → *Teste de WALD*

Hipóteses:

$$H_0: \beta_k = 0$$

$$H_a: \beta_k \neq 0$$

Estatística do Teste:

$$z^* = \frac{b_k}{s\{b_k\}} \sim N(0,1)$$

## Intervalo de Confiança para os parâmetros

IC(1- $\alpha$ ) para  $\beta_k$ :

$$b_k \pm z(1 - \alpha/2)s\{b_k\}$$

IC (1- $\alpha$ ) para  $\theta_k$ :

$$\exp[b_k \pm z(1 - \alpha/2)s\{b_k\}]$$

## Teste da Razão de Verossimilhança para Significância Conjunta de Variáveis Explicativas

$$H_0) \ln \left( \frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_{(m+1)} x_{i(m+1)} + \dots + \beta_p x_{ip}$$

$$H_1) \ln \left( \frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_m x_{im} + \beta_{(m+1)} x_{i(m+1)} + \dots + \beta_p x_{ip}$$

ou ainda:

$$H_0) \beta_1 = \beta_2 = \dots = \beta_m = 0$$

A estatística do teste é definida por:

$$G^2 = -2 (L_0 - L_1) \sim \chi^2 \quad (\text{sob } H_0)$$

com  $(p+1)-(p+1-m)=m$  graus de liberdade

## Teste da Razão de Verossimilhança para Significância de cada Variável Preditora

$$H_0) \beta_j = 0$$

$$H_1) \beta_j \neq 0$$

- Caso particular do teste anterior, onde  $m=1$ .
- Pode-se usar também o **Teste de Wald**:

$$W_j^2 = \left( \frac{b_j}{\hat{ASE}(b_j)} \right)^2 \sim \chi^2 \text{ com } 1 \text{ g.l.}$$

## Deviance

- Sejam

$L_M$  o máximo log da função de verossimilhança para o modelo de interesse;

$L_S$  o máximo do log da função de verossimilhança para o modelo mais complexo, que tem um parâmetro separado para cada logito e fornece um ajustamento perfeito aos logitos amostrais. Este modelo é designado *modelo saturado*.

**Relembrando...**

# Estatística G<sup>2</sup> do Teste da Razão de Verossimilhança

## Modelo Completo:

$$E(Y_{ij}) = \pi_j \quad j = 1, 2, \dots, c$$

onde  $\pi_j$  é a probabilidade de sucesso para cada valor distinto de X,  $j=1,2,\dots,c$ .

O modelo completo no caso da regressão logística é usualmente chamado de **modelo saturado**.

## Modelo Restrito (sob H<sub>0</sub>):

$$E[Y_{ij}] = \pi(x) = \frac{\exp(\beta_0 + \beta_1 x)}{1 + \exp(\beta_0 + \beta_1 x)}$$

## Estatística do Teste:

Considerando a estatística do teste da razão de verossimilhança:

$$G^2 = -2 \ln \left( \frac{L(R)}{L(F)} \right) = -2 [\ln(L(R)) - \ln(L(F))]$$

As estimativas de máxima verossimilhança para as  $c$  probabilidades  $\pi_j$  modelo completo são dadas pelas proporções amostrais:

$$p_j = \frac{Y_{.j}}{n_j} \quad j = 1, 2, \dots, c$$

$\hat{\pi}_j$  estimativa de  $\pi_j$  pelo modelo reduzido para cada  $X_j$ ,  $j=1,2,\dots,c$ ,

Assim a estatística do teste é dada por:

$$G^2 = -2 \sum_{j=1}^c \left[ Y_j \ln \left( \frac{\hat{\pi}_j}{p_j} \right) + (n_j - Y_j) \ln \left( \frac{1 - \hat{\pi}_j}{1 - p_j} \right) \right]$$

ou então,

$$G^2 = -2 \sum_{j=1}^c \left[ Y_j \ln \left( \frac{\hat{Y}_j}{Y_j} \right) + (n_j - Y_j) \ln \left( \frac{n_j - \hat{Y}_j}{n_j - Y_j} \right) \right]$$

que sob a hipótese H<sub>0</sub>, tem distribuição aproximadamente Qui-quadrado com  $c - k$  graus de liberdade quando  $n_j$  for grande e  $k < c$

$k$  - número de parâmetros do modelo

$c$  - número conjuntos de valores distintos das variáveis

## Deviance

### A deviance do modelo é definida como

$$\text{Deviance} = -2 [L_M - L_S].$$

Tem distribuição  $\sim \chi^2$  com  $\nu$  g.l.

- Compara o modelo M com o modelo S (saturado)
- Testa a hipótese de que todos os parâmetros que estão no modelo saturado, mas não estão no modelo M são nulos

## Deviance Parcial

- Sejam dois modelos,  $M_0$  e  $M_1$  tal que  $M_0$  é um caso especial de  $M_1$
- Dado que o modelo mais complexo ( $M_1$ ) se ajusta, deseja-se testar que o modelo mais simples ( $M_0$ ) se ajusta

$$\begin{aligned} G^2(M_0|M_1) &= -2 [L_0 - L_1] = \\ &= -2 [L_0 - L_S] - \{-2 [L_1 - L_S]\} = \\ &= \text{deviance}_0 - \text{deviance}_1 \end{aligned}$$

Tem distribuição  $\sim \chi^2$  com g.l. igual ao número de parâmetros adicionais não redundantes que existem em

$M_1$  mas não em  $M_0$

## Etapas na Construção de Modelos de Regressão

1. Coleta e preparação dos dados
2. Redução das variáveis explicativas ou preditoras (*para estudos observacionais exploratórios*)
3. Refinamento e seleção do modelo
4. Validação do modelo

## Seleção de Variáveis

### ■ Critérios de Seleção de Variáveis:

- **Critério da Informação de Akaike**

$$AIC_p = -2\ln L(b) + 2p$$

- **Critério Bayesiano de Schwarz**


$$SBC_p = -2\ln L(b) + p\ln(n)$$

- **Critério Log da verossimilhança**


$$-2\ln L(b)$$

Modelos promissores renderão valores relativamente pequenos para esses critérios.


(a)  $AIC_p$  versus  $p$



(b)  $SBC_p$  versus  $p$



(c)  $-2 \log_e(b)$  versus  $p$



## Seleção de Variáveis

### ■ Métodos de Seleção Automáticos:

- *Backward*
- *Forward*
- *Stepwise*

### ■ Comparação entre modelos: → *deviance*

### ■ Existem estratégias para selecionar variáveis explicativas que levam em conta questões como:

- os objetivos do estudo,
- significância estatística relativa,
- multicolinearidade e
- potencial confusão.

### ■ Um processo de seleção proposto por Hosmer et al. (2013, Capítulo 4) utiliza diversas etapas para construir um modelo. De forma abreviada:

- Construir um modelo inicial de efeitos principais usando variáveis explicativas que incluam as variáveis importantes conhecidas e outras que mostrem qualquer evidência de serem relevantes quando usadas como únicos preditores (por exemplo, tendo  $p\text{-valor} < 0,20$ ).
- Conduzir a eliminação backward, mantendo uma variável se for significativa em algum nível mais rigoroso ou mostrar evidências de ser um fator de confusão relevante, no sentido de que o efeito estimado de uma variável-chave muda substancialmente quando ela é removida.
- Adicione ao modelo quaisquer variáveis que não foram incluídas na etapa 1, mas que sejam significativas ao ajustar as variáveis no modelo após a etapa 2, uma vez que uma variável pode não estar significativamente associada a  $Y$  mas pode dar uma contribuição importante na presença de outras variáveis.
- Verifique se há interações plausíveis entre variáveis no modelo após a etapa 3, usando testes de significância em níveis convencionais como 0,05.
- Realizar investigações diagnósticas de acompanhamento.

**Table 5.1** Results of fitting several logistic regression models to predict horseshoe crab satellites.

Model	Explanatory Variables	Deviance	<i>df</i>	AIC	Models Compared	Deviance Difference
1	None	225.8	172	227.8		
2	<i>C</i>	212.1	169	220.1	(2) - (1)	13.7 ( <i>df</i> = 3)
3	<i>S</i>	223.2	170	229.2	(3) - (1)	2.5 ( <i>df</i> = 2)
4	<i>W</i>	194.5	171	198.5	(4) - (1)	31.3 ( <i>df</i> = 1)
5	<i>C</i> + <i>W</i>	187.5	168	197.5	(5) - (2)	24.6 ( <i>df</i> = 1)
					(5) - (4)	7.0 ( <i>df</i> = 3)
6	<i>C</i> + <i>W</i> + <i>S</i>	186.6	166	200.6	(6) - (5)	0.9 ( <i>df</i> = 2)
7	<i>C</i> + <i>W</i> + <i>C*W</i>	183.1	165	199.1	(7) - (5)	4.4 ( <i>df</i> = 3)

Note: *C* = color, *S* = spine condition, *W* = width.

## Resíduos para o Modelo de Regressão Logística

### ● Resíduo :

■ A análise de resíduos para regressão logística é mais difícil do que para modelos de regressão linear porque as respostas  $Y_i$  assumem apenas os valores 0 e 1. Consequentemente, o  $i$ -ésimo resíduo ordinário (comum),  $e_i$  assumirá um de dois valores:

$$e_i = \begin{cases} 1 - \hat{\pi}_i & \text{if } Y_i = 1 \\ -\hat{\pi}_i & \text{if } Y_i = 0 \end{cases}$$

## Resíduos para o Modelo de Regressão Logística

### ● Resíduo de Pearson:

O resíduo de Pearson para o ajuste no ponto  $i$  é dado por:

$$e_i = \frac{f_{1i} - n_i \hat{\pi}_i}{\sqrt{[n_i \hat{\pi}_i (1 - \hat{\pi}_i)]}}$$

■ onde:  $f_{1i}$  - número de sucessos para  $n_i$  repetições do  $i$ -ésimo conjunto de valores das variáveis explicativas.

$n_i \hat{\pi}_i$  - número de sucessos ajustado ou esperado.

## Resíduos para o Modelo de Regressão Logística

### ● Resíduo de Pearson studentizado:

O resíduo de Pearson para o ajuste no ponto  $i$  é dado por:

$$r_{SP_i} = \frac{r_{P_i}}{\sqrt{1 - h_{ii}}}$$

$$H = \hat{W}^{\frac{1}{2}} X (X' \hat{W} X)^{-1} X' \hat{W}^{\frac{1}{2}}$$

## Resíduos para o Modelo de Regressão Logística

### ● Deviance Residual:

O resíduo de Pearson para o ajuste no ponto  $i$  é dado por:

$$dev_i = \text{sign}(Y_i - \hat{\pi}_i) \sqrt{-2[Y_i \log_e(\hat{\pi}_i) + (1 - Y_i) \log_e(1 - \hat{\pi}_i)]}$$

■ onde:  $f_{1i}$  - número de sucessos para  $n_i$  repetições do  $i$ -ésimo conjunto de valores das variáveis explicativas.

$n_i$  - número de sucessos ajustado ou esperado.



## Resumindo Poder Preditivo

- **Poder preditivo** - quão bem podemos prever o resultado da variável de resposta usando o ajuste do modelo.

### ■ Tabelas de Classificação

Classifica o resultado binário  $Y$  com uma previsão de se  $Y = 0$  ou  $1$ .

A previsão para a observação  $i$  é :

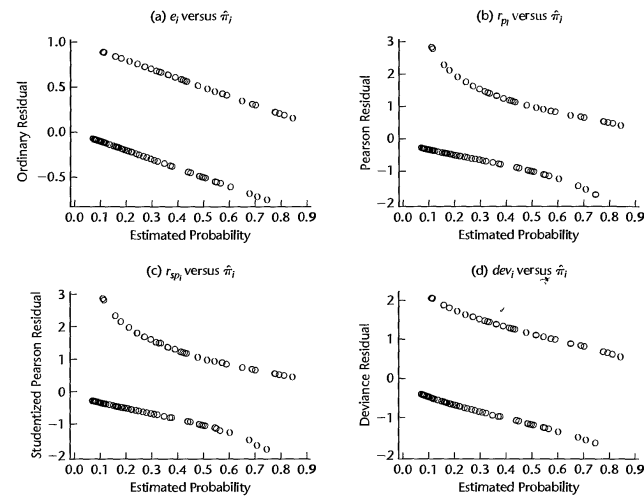
$$\hat{Y}_i = 1 \text{ quando } \hat{\pi}_i > \pi_0$$

$$\hat{Y}_i = 0 \text{ quando } \hat{\pi}_i \leq \pi_0$$

- Uma possibilidade é tomar  $\pi_0 = 0,5$ .

Entretanto, se uma proporção baixa (alta) de observações tiver  $Y = 1$ , o ajuste do modelo pode nunca (sempre) ter  $\hat{\pi}_i > 0,5$ , caso em que nunca (sempre) se prevê  $\hat{Y}_i = 1$ .

- Outra possibilidade toma  $\hat{\pi}_0$  como a proporção amostral de 1



Actual	Prediction, $\pi_0 = 0.6416$		Prediction, $\pi_0 = 0.50$		Total
	$\hat{y} = 1$	$\hat{y} = 0$	$\hat{y} = 1$	$\hat{y} = 0$	
$y = 1$	75	36	96	15	111
$y = 0$	19	43	31	31	62

- **Sensibilidade:** é a probabilidade de o teste ser positivo, sabendo-se que o evento de interesse ocorre.
- **Especificidade:** é a probabilidade de o teste ser negativo, sabendo-se que o evento de interesse não ocorre.

- Probabilidade de Classificações corretas

$$\begin{aligned} P(\text{Classificação correta}) &= P(Y = 1 \text{ e } \hat{Y} = 1) + P(Y = 0 \text{ e } \hat{Y} = 0) = \\ &= P(\hat{Y} = 1 | Y = 1)P(Y = 1) + P(\hat{Y} = 0 | Y = 0) = \\ &= \text{sensibilidade } P(Y = 1) + \text{especificidade } P(Y = 0) \end{aligned}$$

que é uma média ponderada de sensibilidade e especificidade.

## Curva ROC

- Uma curva ROC (*Receive Operating Characteristic*) é um gráfico que mostra a sensibilidade e a especificidade das previsões para todos os cortes possíveis  $\pi_0$ .
- Essa curva é mais informativa do que uma tabela de classificação, pois resume o poder preditivo para todos os  $\pi_0$  possíveis.

